

Министерство науки и высшего образования Российской Федерации
Федеральное государственное бюджетное образовательное учреждение
высшего образования

**«Новгородский государственный университет имени Ярослава
Мудрого»**

Политехнический институт
Кафедра информационных технологий и систем

ОТЧЁТ по учебной практике

Задание 3. Работа с данными

Поиск, описание наборов данных, предобработка и протокол сбора

по направлению 09.04.01 «Информатика и вычислительная техника»,
профиль «Искусственный интеллект»

Выполнил: студент группы 5095 С. Каримов

Руководитель: _____ / _____

Великий Новгород — 2026

Поиск, обоснование, описание и протокол подготовки данных для системы генерации и оценки рифмованной русской поэзии.

1. Поиск и обоснование

Требования к данным проекта:

- русскоязычная поэзия (силлабо-тоника), строфы с регулярной рифмовкой;
- желательна разметка: ударения, схема рифмовки, метр (для обучения/валидации детектора рифмы);
- открытая лицензия, пригодная для исследовательского использования;
- достаточный объём и разнообразие авторов/эпох (чтобы метрики не переобучались на одном стиле).

Зачем именно эти данные. Для *оценки* детектора рифмы нужна разметка рифм/ударений — ключевые Rifma и ArsPoetica (Koziev), совместимые с RPST. Для *генерации* и языкового разнообразия — крупные неразмеченные корпуса (stihi_ru, НКРЯ-поэтический, PULPO). Мультиязычные/англ. корпуса (Gutenberg Poetry) — для кросс-языковых экспериментов и сравнения с зарубежным SOTA.

2. Описание наборов данных (кандидаты)

Датасет	Язык	Объём	Разметка	Лицензия	Источник
Rifma	RU	5002 фрагмента	ударения + схема рифмовки	см. репо	https://github.com/Koziev/Rifma
ArsPoetica	RU	~8.5k стихов	ударения	см. карточку	https://huggingface.co/datasets/inkoziev/ArsPoetica
stihi_ru (Gusev)	RU	крупный корпус	нет (сырой текст)	см. карточку	https://huggingface.co/datasets/IlyaGusev/stihi_ru
Поэтический подкорпус	RU	большой	метр/рифма/	усл. НКРЯ	https://ruscorpora.ru

НКРЯ			строфика + морфология		/page/corpus-poetic-index/
PULPO	мультязычный (вкл. RU)	>72–95М слов	нет (сырой)	см. карточку	https://huggingface.co/datasets/linhd-postdata/pulpo
Gutenberg Poetry Corpus	EN	3,085,117 строк	нет	CC0	https://github.com/aparrish/gutenberg-poetry-corpus
poems/ (корпус проекта)	RU	50 строф / 359 строк	нет	классика (PD)	каталог репозитория

Объёмы/лицензии указаны по карточкам источников — перед использованием сверить актуальные условия (особенно НКРЯ и HF-датасеты).

Основной выбор для ВКР:

- обучение/тюнинг детектора рифмы и его валидация — Rifma + ArsPoetica;
- языковое разнообразие и генерация — stihi_ru (+ НКРЯ-поэтический при доступе);
- кросс-язык/сравнение — PULPO, Gutenberg Poetry.

3. Описание источников (provenance)

- Koziev (Rifma, ArsPoetica, RPST, NLP_Datasets) — автор RPST; разметка совместима с инструментом, что снижает рассогласование форматов (https://github.com/Koziev/NLP_Datasets).
- НКРЯ — академический корпус с профессиональной стиховедческой разметкой; доступ по условиям корпуса (некоммерческое исследовательское использование).
- Hugging Face (stihi_ru, ArsPoetica, PULPO) — лицензия и происхождение указаны в карточках; stihi_ru собран с публичной площадки stihi.ru — требуется проверка прав на тексты конкретных авторов.
- Project Gutenberg (Gutenberg Poetry) — общественное достояние, CC0.

Лицензионная чистота: тексты современных авторов (stihi.ru и т.п.) могут быть защищены авторским правом. Для ВКР приоритет — public domain (классика) и датасеты с явной открытой лицензией; современные тексты использовать только в агрегированном/метрическом виде или с разрешения.

4. Предобработка

Пайплайн (частично реализован в src/Model/TextConverter.py):

1. Нормализация: UTF-8, приведение к нижнему регистру, удаление пунктуации (для детектора), разбиение на строки и слова. Сохранение исходного варианта с пунктуацией/регистром — для показа и разметки клаузул.
2. Сегментация на строфы: по пустой строке; фильтр строф длиной ≥ 2 строк.
3. Дедупликация: удаление точных и near-duplicate строф (хэш/шингл).
4. Фильтрация: язык (русский), длина, кодировка, отсеивание технического мусора.
5. Разметка ударений (RPST) — хвосты/клаузулы; для размеченных датасетов — сверка с эталоном.
6. Формирование примеров: (строфа, целевая схема, метки рифмующихся пар).
7. Разбиение train/val/test со стратификацией по схеме рифмовки и размеру; фиксация random seed и версии датасета.

5. Протокол сбора данных

8. Источники и права: фиксировать происхождение и лицензию каждого текста; для PD — указывать автора/издание; для HF/НКРЯ — ссылку на карточку и условия.
9. Сбор: использовать готовые датасеты (предпочтительно) вместо парсинга; при парсинге — соблюдать robots.txt и условия площадки, хранить дату загрузки.

- 10.Очистка: нормализация (см. §4), дедупликация, отсев не-русских/битых фрагментов.
- 11.Разметка: автоматическая (RPST: ударения, метр, рифма) + выборочная ручная проверка ≥ 2 аннотаторами; согласие — Cohen's κ .
- 12.Версионирование: каждый релиз датасета — с версией, хэшем и описанием изменений; неизменяемые train/val/test split'ы.
- 13.Метаданные: на каждый пример — источник, лицензия, схема, размер, метки.
- 14.Хранение: сырые/обработанные данные отдельно; крупные файлы — вне git (LFS или внешнее хранилище), в репо — только скрипты и манифесты.
Формальные требования к пайплайну и метрики оценки — в 04_specification.md (04_specification.md).